

主要车牌识别技术综述

顾秀烨
3130101959

熊青城

海杰文
3130000656

2016 年 6 月 2 日

目录

1	概述	2
2	车牌定位	2
2.1	由 Viola and Jones 的 face detection framework 衍生的一些方法	2
2.1.1	Viola and Jones 的 Robust Real-Time Face Detection 论文简述	2
2.1.2	Detecting and Reading Text in Natural Scenes	5
2.1.3	License Plate Detection Using AdaBoost	8
2.1.4	Real-Time License Plate Recognition on an Embedded DSP-Platform	10
2.2	Brazilian License Plate Detection Using Histogram of Oriented Gradients and Sliding Windows	15
2.3	openALPR 系统所使用的 LBP 特征	16
2.4	Unconstrained Licence Plate and Text Localization and Recognition	16
2.5	自然环境下的车牌定位与字符分割方法的研究	17
2.6	开源系统 EasyPR 中用到的形态学方法与颜色定位法。	20
2.6.1	使用 Sobel 寻找垂直边缘	20
2.6.2	颜色定位与偏斜扭正	23
2.6.3	EasyPR 现阶段的车牌定位方式	24
2.6.4	偏斜扭转	25
2.6.5	SVM 训练	29
3	字符分割	30
4	字符识别	30
5	总结	30

1 概述

本文旨在分析车牌识别整个流程中各个阶段的所有方法，主要分为车牌定位、字符分割以及字符识别。在多篇论文中作者们都提到，车牌检测在整个车牌定位、识别系统中是最耗费计算时间的，所以针对车牌定位有很多方法，其中许多算法都是由人脸识别算法改编而来。目前车牌定位的主要方法有以下几种。

1. 对 Viola & Jones 的经典论文 [7] 中的基于 AdaBoost 的人脸检测系统的推广，Louka 的论文 [5] 与论文 [4]，包括国内的一些论文都是通过对 Viola & Jones 提出的人脸检测 framework、对特征选择、对 Adaboost 算法进行改进来实现车牌监测的。
2. HOG 方法与 SVM 方法相结合
3. 开源系统 OpenALPR 使用了 LBP 算法 (LBP 算法通常用于人脸检测) 以及 SVM。
4. extremal regions 方法 [3] 该方法主要用于检测任意国家的车牌，能很好地处理有遮挡、光线较差的情况。在 07 年的 ACCV 的一篇论文中，该方法被称为 MSER[6] 检测方法。这个方法的特别之处在于，它可以同时完成初步的字符分割与车牌检测两个任务。
5. 哈工大的一篇车牌定位与字符分割的硕士论文 [11]，使用了粗定位与精确定位两个阶段，车牌粗定位使用了一种基于梯度空间下运用连通区域水平聚类分析的方法，此后的车牌精确定位阶段采用了基于车牌梯度宽度跳变分割和 HSV (Hue, Saturation, Value) 色彩分割的方法。
6. 开源系统 EasyPR 提出了两种方法，(a) 使用二值图像处理的一系列方法检测出垂直边缘 (车牌区域垂直边缘多而密集)，(b) 颜色定位法，这两种方法相结合，找到一些可能为车牌的图块，再通过训练好的 SVM 模型进行最终判断。

字符分割一般由对车牌图像进行预处理 (去除边框、铆钉，颜色调整)、二值化、分割算法、后期处理 (post-processing, optional) 4 个步骤组成，并且分割时一般会考虑先验知识 (车牌的颜色、大小，字符的大小、位置等)。每个步骤都有一些常见方法。许多论文与开源系统都是这些常用方法的组合，并加上一些改进，或通过后处理进行调整。所以在这里首先简述每个步骤的常用方法。

用于车牌字符识别的主要方法有两大类：分类器方法与模式、模板匹配方法。许多车牌识别系统中，会有 Post processing 的步骤，目的是提高识别的准确率。

2 车牌定位

2.1 由 Viola and Jones 的 face detection framework 衍生的一些方法

2.1.1 Viola and Jones 的 Robust Real-Time Face Detection 论文简述

Viola and Jones 的人脸检测系统的主要贡献有三个：

1. 提出 "Integral Image" 的概念，提高了 detector 的计算速度。
2. 使用 Adaboost 学习算法从大量的可能特征中筛选出少量的重要的特征，以实现一个简单而有效的分类器。

3. 将分类器级联，使得显然的非人脸区域很快地被丢弃，而后面的分类器可以致力于区分那些更可能是人脸的区域。

他们首先选择了一些相当简单的特征 (reminiscent of Haar basis functions)，他们认为，使用特征而不直接使用像素信息的重要原因是特征可以给出一些 ad-hoc domain knowledge，而直接使用像素信息很难获得这些知识。另一方面，基于特征的系统比起基于像素的系统也快得多。特征的示例见下图，他们使用的都是规则的长方形特征，特征的值子窗口中黑白区域的像素值之和的差值。




图 1: 样例的矩阵特征相对于检测窗口显示。白色矩阵之和减去灰色矩阵之和。二矩阵特征显示在 (A) 和 (B) 之中。(C) 为三矩阵特征,(D) 为四矩阵特征。

对每一张待检测照片，计算出它的积分图像，就可以很迅速地计算出每个检测子窗口上的各个特征的值。他们在总结中提到，为了实现真正的尺度不变性，几乎所有的人脸检测系统都需要对每一张待检测图片的多个尺度进行检测。使用积分图像，就可以通过改变窗口大小、保持检测图片大小不变的方式，快速地对一张图片的各个尺度进行检测。

为了提高检测系统的鲁棒性，配合 Adaboost[10] 算法，首先生成一个非常巨大的矩形特征集。对于每一个特征，生成一个弱分类器：选择使得误判的样例数最少的阈值生成一个二元分类器。

然后使用 Adaboost 算法，选择非常少的弱分类器。Adaboost 算法逐个选择加权误差最小的弱分类器，并且每添加一个特征，就更新样例的权重，使得被错误分类的样例获得更高的权重。最后生成一个强二元分类器，是选择出来的弱分类器的线性组合。Adaboost 算法如下：其中，弱分类器的选择可以使用这样的算法：

对于每一个特征，将样例按照特征的值排序，对于每一个排好序的样例，维护 4 个值：所有正样本的权重之和 T^+ ，所有负样本的权重之和 T^- ，排在当前样例之前的正样本的权重之和 S^+ 与排在当前

Algorithm 1 Adaboost

- 1: 给定数据图像 $(x_1, y_1), \dots, (x_n, y_n)$, 其中 $y_i = 0, 1$, 分别为负面和正面数据。
- 2: 对于 $y_i = 0, 1$ 分别初始化权重 $w_{1,i} = \frac{1}{2m}, \frac{1}{2l}$, 其中 m 和 l 分别是负面数据和正面数据的数量。
- 3: **for** $i = 1$ to T **do**
- 4: 标准化权重, $w_{t,i} \leftarrow \frac{w_{t,i}}{\sum_{j=1}^n w_{t,j}}$
- 5: 选择基于以下错误的最佳弱分类器 $\epsilon_t = \min_{f,p,\theta} \sum_i w_i |h(x_i, f, p, \theta) - y_i|$
- 6: 定义 $h_t(x) = h(x, f_t, p_t, \theta_t)$, 其中 f_t, p_t 和 θ_t 是 ϵ_t 最小时的取值
- 7: 更新权重:

$$w_{t+1,i} = w_{t,i} \beta_t^{1-e_i}$$

若 x_i 被分类正确, $e_i = 0$, 否则 $e_i = 1$, 而 $\beta_t = \frac{\epsilon_t}{1-\epsilon_t}$

8: **end for**

9: 最终强分类器为:

$$C(x) = \begin{cases} 1 & \sum_{t=1}^T a_t h_t(x) \geq \frac{1}{2} \sum_{t=1}^T \alpha_t \\ 0 & otherwise \end{cases}$$

where $\alpha_t = \log \frac{1}{\beta_t}$

样例之前的负样本的权重之和 S^- 。那么, 以当前样例的特征的值作为阈值的弱分类器的误差为:

$$e = \min(S^+ + (T^- - S^-), S^- + (T^+ - S^+))$$

这样, 每次选择最优弱分类器的时间复杂度为 $O(NK)$, N 为样本数, K 为总特征数。另外, 也可以证明 adaboost 算法的训练误差是可以被控制的:

Algorithm 2 Adaboost 误差

- 1: 运行 AdaBoost
- 2: 让 $\epsilon_t = \frac{1}{2} - \gamma_t$
- 3: 所以有

$$\begin{aligned} E_t(H_{final}) &\leq \prod_t [2\sqrt{\epsilon_t(1-\epsilon_t)}] \\ &= \prod_t \sqrt{1-4\gamma_t^2} \\ &\leq \exp(-2 \sum_t \gamma_t^2) \end{aligned}$$

4: 因此:

$$\begin{aligned} & \text{if } \forall t: \gamma_t \geq \gamma > 0 \\ & \text{then } E_t(H_{final}) \leq e^{-2\gamma^2 T} \end{aligned}$$

其中, T 为最终选择的特征的个数。

作者认为, Adaboost 算法的关键优势在于它学习的速度, 在于每一轮选择特征时, 算法将已选择的特征的信息编码到了样例的权重中。

另外，该系统使用了级联使用 Adaboost 得到的分类器，以提高检测能力并且减少计算时间。级联分类器的核心思想是首先使用更小的、更快速的分类器拒绝掉尽可能多的非人脸子窗口（在扫描过程中，绝大多数的子窗口中没有人脸），同时保留几乎所有的人脸子窗口（通过降低分类器的阈值），之后，使用更复杂的分类器来达到低加阳性率。决策的总体过程使用的是退化的决策树的形式，作者称其为“级联”。另外，后面的分类器接受训练时使用的是被前面的分类器所接受的样例（其中的非人脸样例更难区分），这样，他们可以解决更难的分类问题。级联分类器的运作过程如下图所示。




图 2: 从语义上描述级联检测，一系列的分类器作用于每一个子窗口。其中初始分类器以非常少的处理解决掉大量的负面数据，接下来的分类器以额外的计算处理附加的负类。在几个阶段的处理之后，子窗口数量的彻底减少了。进一步的处理可以采取任何形式，比如额外的级联或是替代的检测系统。

级联检测器的训练算法如下所示：

最后，Viola 和 Jones 在论文的结论中提到，初步的实验表明，其他物体的高效的检测器，如行人、车辆，也可以通过这种方式构建。

2.1.2 Detecting and Reading Text in Natural Scenes

在这篇论文中 [9]，针对城市中随意拍摄到的文本，Chen 和 Yuille 利用 Viola 和 Jones 的算法框架，根据文本区域的特征分析，选择了一些特征，送到 AdaBoost machine 中，获得级联的 Adaboost 分类器。最后使用商业 OCR 软件阅读文字。获得了超过 90% 的正确率。

作者认为，特征集的选择对算法的成功与否与透明性至关重要。由于不同文本之间的空间差异性远远强于人脸，例如眼睛在人脸上的位置是相似的，不同人的眼睛也有一定相似性，而字母的位置、形状在不同文本中差异很大。通过 PCA 分析，文本有更多的非零特征值，文本需要 150 个 components 才能获得 90% 的 variance，而人脸只需要 15 个 components。

同时，作者强调，我们应该选择富有意义的、能传达出信息的特征，并且他们在不同的文本区域上可以得到相似的结果（低熵值，low entropy）。他们分析了文本区域的统计特征，得到如下一些结论。首先，如下图所示，文本的 x , y 方向上的导数的平均数、方差：

Algorithm 3 级联检测器训练算法

```
1: 用户选择每层的最大假阳性接受率  $f$  和的最小检测接受率  $d$ 
2: 用户选择全局的假阳性率  $F_{target}$ 
3:  $P$ = 阳性集合
4:  $N$ = 阴性集合
5:  $F_0 = 1.0; D_0 = 1.0$ 
6:  $i = 0$ 
7: while  $F_i > F_{target}$  do
8:    $i \leftarrow i + 1$ 
9:    $n_i = 0; F_i = F_{i-1}$ 
10:  while  $F_i > f \times F_{i-1}$  do
11:     $n_i \leftarrow n_i + 1$ 
12:    使用 AdaBoost 以及  $P$  和  $N$  训练一个带有  $n_i$  个特征的分类器
13:    在验证集上评价级联测试器来决定  $F_i$  和  $D_i$ 。
14:    降低第  $i$  个分类器的阈值，直到当前级联分类器的检测率最少为  $d \times D_{i-1}$ 
15:  end while
16:   $N \leftarrow \emptyset$ 
17:  如果  $F_i > F_{target}$ ，则在非脸图像的集合上计算当前级联检测器，并将错误检测的图像放入集合  $N$ 
18: end while
```




图 3: x 方向上的导数值在中间区域比较大, 而 y 方向上的导数值在顶部与底部比较大, x 方向上的导数值的方差在中间区域比较大, 而 y 方向上的方差普遍比较小 (低熵值)

他们选择的第一类特征基于上述观察结果, 设计了对应于 $x y$ 方向上导数的块状特征、可以包含一个文字的对称的块状特征, 特征值主要为 $x y$ 方向上导数的平均值与标准差:




图 4: 块状模式。在这个区域里计算的平均值有低熵, 因为在上图中的波动已经被平均所消除。

一个好的特征 $f(I)$ 可以很好地区分两个概率分布函数 $P(f(I)|text)$ 与 $P(f(I)|non - text)$, 若 $P(f(I)|text)$ 可以有一个很强的峰, 则说明这个特征具有低熵值性。

他们选择的第二类特征基于强度、梯度方向、强度梯度值的直方图, 更加复杂一些:

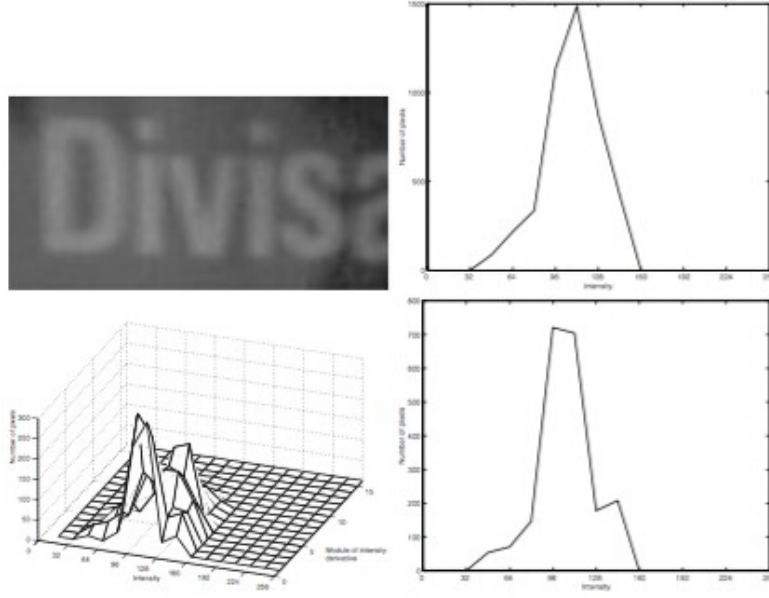


图 5: 原图 (左上) 有单峰的亮度直方图 (右上)。但是联合直方图的题图显示有两个峰 (左下), 右下为其轮廓。亮度直方图被有高亮度梯度和亮度值的边像素所污染。它在前景与背景之间, 亮度梯度信息可以用来帮助

他们还选择了更加复杂的第三类特征, 只用于级联分类器后面的阶段。第三类特征基于边缘检测, 通过强度梯度阈值化、边缘连接处理。这一类特征可以计算延长的边缘的数量。具有比较低的熵值。

在使用级联的 Adaboost 强分类器以后, 他们做了二值化操作与一些扩展操作, 再将车消除这种污染。牌送入商业 OCR 软件进行识别。这两步操作对我们有一定的借鉴意义。

他们首先使用了 Niblack 提出的自适应的二值化算法的变种 (Wolf 认为该算法与 Yanowitz-Bruckstein 的方法是最成功的二值化算法):

$$T_r(x) = \mu_r(x) + k \cdot \sigma_r(x)$$

T_r 为阈值, x 为像素点, r 为一个子窗口的大小, μ_r 与 σ_r 是该子窗口中像素值的平均值与标准差。Niblack 的 r 值是固定的, 作者的算法自适应地选择 r 值, 因为字符的大小和笔画的粗细都不同。他们选择:

$$r(x) = \min_r (\sigma_r(x) > T_\sigma),$$

其中, T_σ 是一个固定的阈值, 认为标准差小于 T_σ 的窗口为平滑的区域。K 是固定的。

作者接着使用了连通区域算法对字符区域进行扩展, 因为有时使用 Adaboost 算法得到的字符区域是不完整的。

2.1.3 License Plate Detection Using AdaBoost

Louka 的论文 [5] 衡将文本提取的方法 (Chen and Yuille) 与人脸检测的方法 (Viola and Jones) 应用到了 LPR (license Plate Recognition) 系统, 并对这种方法进行评估。

他提到, 通过 PCA 分析, 发现车牌需要的 components 比 Chen 和 Yuille 的文本要少很多, 因为字体、朝向都是比较固定的。他选择特征的标准与 Chen 和 Yuille 一样, 希望有比较低的熵值 (在所有

的车牌上的检测结果比较相似), 而又可以很好地区分车牌区域与非车牌区域。

他们将车牌的大小统一后, 车牌 x , y 方向上的导数绝对值的均值与方差如下图所示:




图 6: x (a) 和中 y (b) 的导数绝对值平均, 以及 x 的方差导数 (c), y 的方差导数 d 。

x 方向上的导数的统计特征与 Chen and Yuille 的相似, 而在 y 方向上可以明显看到车牌上 7 个字符到来的导数的变化。根据这一观察结果, 他们选择了 Haar-like 特征, 将扫描窗口水平或垂直地分为 2-7 个大小相等的子区域, 特征值为一部分子区域上某些值的和减去剩下的子区域上的同一类值的和。示例如下图:




图 7: AdaBoost 所选择的特征类型。有颜色区域之和被减去了无颜色区域之和。

用于求和并相减的值为, 像素强度, 导数, 导数方差。每个特征训练生成一个弱分类器, 在这篇论文中作者使用了类条件密度来训练弱分类器, 这里没有使用阈值, 而是当车牌的类条件密度比非车牌条件密度的大时, 判断为车牌。如下图所示:




图 8: 弱分类器特征的典型类条件密度。这里有明显的大量的错误无法在分类时避免, 然而, 该错误远比 AdaBoost 生效所需的 50% 要低。

这里也使用了积分图像的方法, 对于像素强度, 导数, 倒数方差都可以计算出积分图像, 减少计算时间。方差可以由下面的公式, 通过积分图像, 快速得到。

$$\sigma^2 = m^2 - \frac{1}{N} \sum x^2$$

其中 m 为平均值而 x 为某一像素的亮度导数。

另外, 本文使用了聚类的方法, 使用每一个 group 的均值将检测到的包含同一车牌的临近区域进行合并。

最后, 本文对错误分类的情况进行分析, 并给出了一些解决方案。比如, 利用比较容易检测的车尾灯, 通过检测到的区域距离车尾灯的距离来进一步判断该区域是否为车牌区域。

2.1.4 Real-Time License Plate Recognition on an Embedded DSP-Platform

这篇论文 [4] 在嵌入式 DSP 平台上实现了一个功能完整的车牌检测与识别系统, 可以实时地从视频流中提取出车牌。主要有检测与识别两个模块, 我们在车牌定位这一部分中首先描述它的检测模块。整个系统的工作示意图如下:

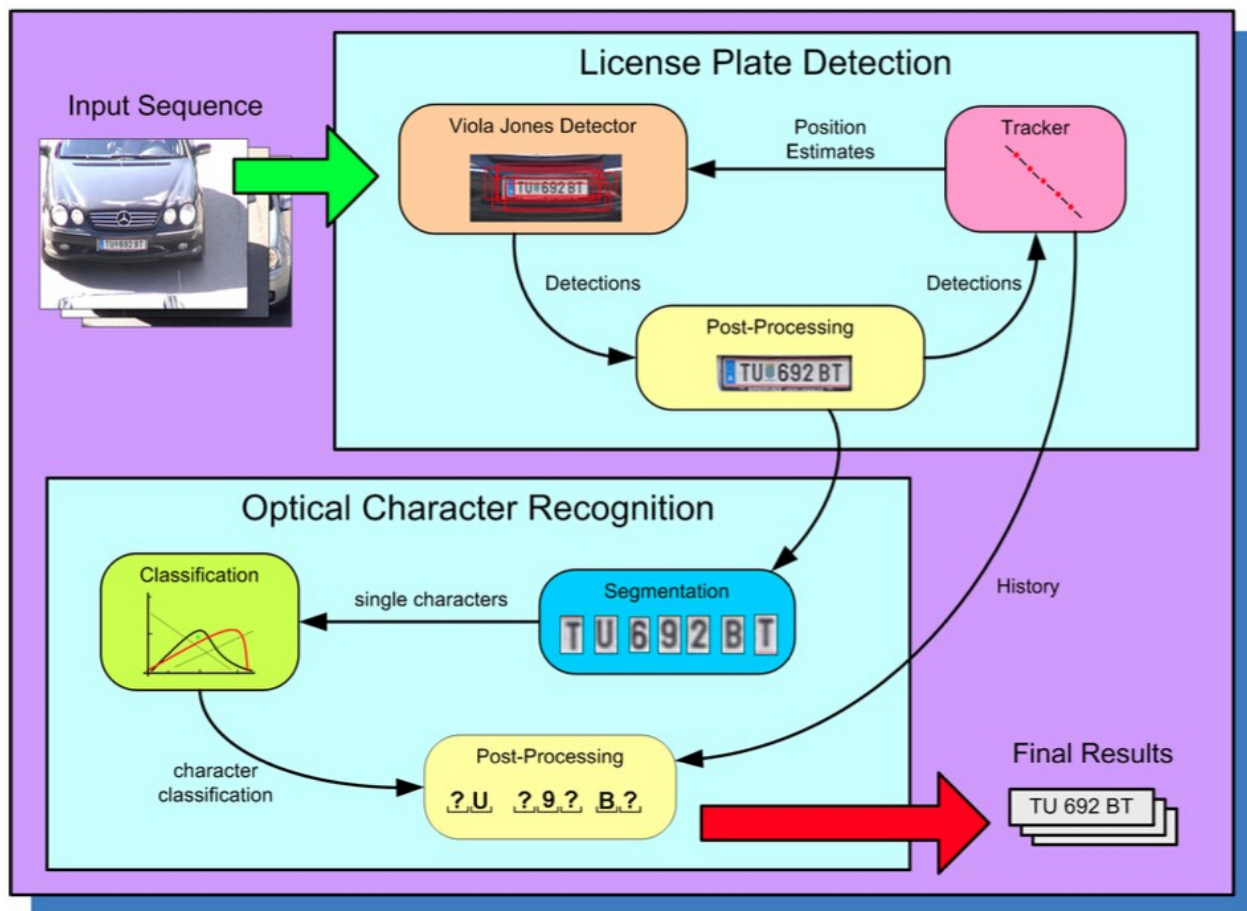


图 9: 该系统包含两个主要模块。给定一个图像序列作为输入，检测模块将检测以及追踪车。而在第二个模块，将会进行图像分割以及字符识别并生成最终结果。

检测部分 检测部分基于 Viola 和 Jones 的 framework，但是根据后续的论文做了很多改进。

1. 使用了 RealBoost 算法，使用自信率预测代替了二元的分类标签。算法基本与 Adaboost 一致，如下所示：

Algorithm 4 自信率预测

- 1: 允许弱假设预测自信度
- 2: 形式上，让 $h_t : X \rightarrow R$

$$\text{sign}(h_t(x)) = \text{prediction}$$

$$|h_t(x)| = \text{confidence}$$

- 3: 使用同样的更新:

$$D_{t+1}(i) = \frac{D_t(i)}{Z_t} \cdot \exp(-\alpha_t y_i h_t(x_i))$$

以及组合弱假设的相同规则

2. 为级联分类器添加了阶段间特征传递 [1]

这篇论文的核心思想在于，作者认为，在 Viola and Jones 提出的级联算法中，每一个阶段的分类器，都生成了一个新的训练集，然后使用 Adaboost 算法在一个全新的问题上跑出的结果，这个分类器完全抛弃了前面的阶段中的生成的分类器。

他们认为，前一个阶段生成的分类器对于当前的新的训练集，还是可以作为当前分类器的一部分（当前分类器的起点，第一个弱分类函数），只需要调整一下阈值，因为前面的阶段为了保证不把人脸误判为非人脸，会特意调低阈值。

$$H_s(x) = \text{sign}(f_s(x) - \gamma_s)$$

$$f_s(x) = \alpha_0 H'_{s-1}(x) + \sum_{t=1}^T \alpha_t h_t(x)$$

其中

$$\alpha_0 = \frac{1}{2} \ln \frac{1 - \epsilon_0}{\epsilon_0}$$

而且 H'_{s-1} 是前一个阶段带有阈值 τ_s 的弱分类器

$$H'_{s-1}(x) = \text{sign}(f_{s-1}(x) - \tau_s)$$

原弱分类器的带权错误 ϵ_0

$$\epsilon_0 = \sum_{i=1}^m D_0(i) [\text{sign}(f_{s-1}(x_i) - \tau_s) \neq y_i]$$

其中 $D_0(i)$ 是第 i 个数据 x_i, y_i 的权重。而阈值 τ_s 将被设置为最小的 ϵ_0 将前一个阶段的得到的分类器作为当前分类器的第一个弱分类器有以下原因：

- (a) 由于训练集发生了变化，而前一个阶段得到的分类器作为当前阶段的第一个弱分类器，所以每个训练样本的权重服从均匀分布，不会影响弱分类器的表现。
- (b) 它可以将 Adaboost 的学习过程集中于解决没有被前面阶段所解决分类问题。
- (c) 3. 这样的分类器有一个很大的优势是，前一个阶段的 $f_s(x)$ 都在上一阶段已经计算过了，所以 $H'_{s-1}(x)$ 的计算成本很低，作者称之为零计算成本。

实验表明，使用跨阶段特征后，可以使用更少的层数，达到同样的假阳性与假阴性，同时没有增加计算复杂度。而且比 Viola and Jones 的级联快了 25%。

3. 特征池中增加了边沿朝向直方图特征 (EOH)[2]

Levi 的这篇论文致力于寻找在很小的训练集上也能表现得很好的特征。他们使用边方向直方图 (EOH)，并且证明这种特征能够达到上述目的。

EOH 的示意图与其他特征的对比图如下：

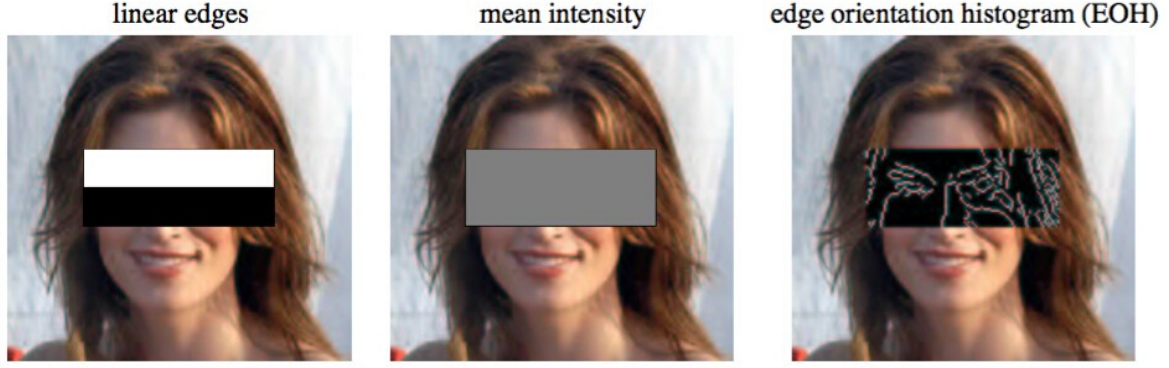


图 10: 我们展示使用局部方向直方图在脸的子区域可以大幅提高性能, 而只使用强度平均特征将大大降低性能。

选择 EOH 的理由有: EOH 与全局光照的变化无关, 并且能够捕捉到前两种特征很难捕捉到的几何特性。

EOH 的获得, 首先使用了 sobel masks, 因为他们简洁并高效。若将边沿朝向分为 K 个组, 则每个像素点获得 K 个特征值 ($\phi_k(x, y)$): 我们可以使用 Sobel 算子计算点 (x, y) 的梯度,

$$G_x(x, y) = Sobel_x \times I(x, y)$$

以及

$$G_y(x, y) = Sobel_y \times I(x, y)$$

其中 $Sobel_x$ 和 $Sobel_y$ 分别是 x 和 y Sobel 算子。边在点 (x, y) 的强度为:

$$G(x, y) = \sqrt{G_x(x, y)^2 + G_y(x, y)^2}$$

为了忽略噪声, 我们对 $G(x, y)$ 阈值化

$$G'(x, y) = \begin{cases} G(x, y) & \text{if } G(x, y) \geq T \\ 0 & \text{otherwise} \end{cases}$$

Sobel 算子的一个主要缺陷是我们必须手动设置阈值。在我们的实验中, 阈值被设置在 80 到 110 之间。

边的导向为

$$\theta(x, y) = \arctan \frac{G_y(x, y)}{G_x(x, y)}$$

我们接下来将所有的边分成 K 分, 我们将第 k 个部分的值记为

$$\Phi_k(x, y) = \begin{cases} G(x, y) & \text{if } \theta(x, y) \in bin_k \\ 0 & \text{otherwise} \end{cases}$$

我们发现 K 在 4 到 8 之间系统的普遍性较好并且只需要有限的内存。

在每个子窗口上定义 E_k :

$$E_k(R) = \sum_{(x, y) \in R} \Phi_k(x, y)$$

类似前面的描述，EOH 特征也可以通过 Integral Image 的方式快速获得。接下来，论文定义了一系列 EOH 特征：

$$A_{k1,k2}(R) = \frac{E_{k1}(R) + \epsilon}{E_{k2}(R) + \epsilon}$$

通过设定阈值，该特征决定了，相对于 k2 朝向而言，k1 朝向是否有决定性作用。

主导方向特征：

$$B_k(R) = \frac{E_k(R) + \epsilon}{\sum_i E_i(R) + \epsilon}$$

对称特征：

$$Symm(R_1, R_2) = \frac{\sum_{k \in K} |E_k(R_1) - E_k(R_2)|}{sizeof(R_1)}$$

实验表明，使用 EOH 系列特征，可以从很小的数据库（250 张正面脸）中学习，并获得很好的表现。另外，论文将 EOH 特征作用在区分椅子的应用中，也取得了很好的效果。所以，EOH 特征是一种很好的特征，可以用于多种物体的检测。

Post-processing 部分 处理包含同一车牌的许多区域，使用了非最大值抑制方法，选择 confidence value 最大的区域代表这一组检测到的区域。

Tracker 部分 一个 Kalman tracker 被整合到了系统中，Tracker 主要用于更新并且预测同一张车牌在视频后面的帧中的位置，然后将检测器的搜索范围限定在一定的区域内，这样会比重新扫描整张图片快。另外，tracker 对字符分类步骤也有很大的帮助。如下图所示：


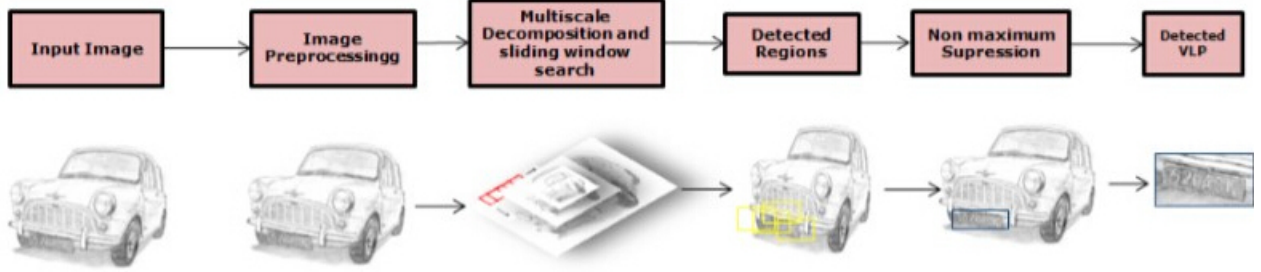


图 11: 上图描述了所有动态和静态的可能场景。在这个情况下，物体被假设从图中上部进入，一个追踪器预测物体在下一帧中的出现，将搜索限制在小的范围之内。

2.2 Brazilian License Plate Detection Using Histogram of Oriented Gradients and Sliding Windows

在这篇论文 [8] 中，作者将 Dalal 提出的用于人体检测的 HOG 算法应用到巴西车牌检测系统中去，实现了大于 98% 的查全率，大于 78% 的正确率。

整体流程见下图：



主要算法流程：

1. 图像被分成若干个单元，对于每个单元，可以计算得到一张朝向梯度的直方图（HOG）。

使用 1 维 Sobel 算子得到 x、y 方向上的梯度：

$$dx = I(x+1, y) - I(x-1, y)$$

$$dy = I(x, y+1) - I(x, y-1)$$

接着计算 magnitude 与 orientation：

$$m(x, y) = \sqrt{dx^2 + dy^2}$$

$$\theta(x, y) = \arctan\left(\frac{dy}{dx}\right)$$

2. 为了使得特征不受光照强度、对比度的影响，有效的局部对比度正规化对于好的表现是必要的。

单元们被组成块，对于每个块进行正规化操作。块是重叠的，所以一个单元可以属于多个块，获得不同的正规化。最后每个单元的描述符为他所从属的所有在检测窗口中的块的所有组件所组成的向量。

这里，为了效率，选择 L1 范数作为正则化的方法：

$$v' = \frac{v}{\sqrt{\|v\|_1^2 + \epsilon^2}}$$

v 是一个给定块中所有单元的直方图向量。通常也会使用高斯函数，给中心的像素点更高的权重。

3. 使用数量级与方向，就可以构造出朝向梯度直方图。即，按照方向放到不同的直方中，数量级作为权重，在 Dalal 的论文中，为了使得介于两个直方之间的方向可以获得更好的分类，所以会将每个像素点放到两个直方中，权重为将他的数量级按照他的方向到两个相邻直方的距离按比例分配。

4. 为了检测出不同尺度的车牌，对每一章图片，构造尺度不同的金字塔。
5. 对于金字塔中的每一层，使用固定大小的窗口，以固定的步长，提取出 HOG 特征，送到训练好的分类器中（在这篇论文中，使用的是线性的 SVM）进行检测。

2.3 openALPR 系统所使用的 LBP 特征

LBP (local binary pattern) 也是一种特征向量。他是这么计算的：

1. 将整个检测窗口分成单元（例如，16*16）
2. 对于每个 cell 中的每个像素，将它与它的 8 个相邻像素点相比较。若中心像素点的值大于邻居的，则写 0，反之则写 1。这样，每个像素点就有了 1 个 8 位二进制数字。




图 12: 三个邻近数据被用来定义材质并用来计算 LBP。

3. 对每个单元，计算直方图，即每种 8 位二进制数字的频率。这个直方图可以看做是 256 维的特征向量。
4. 可以选择性地正规化直方图。方法类似 HOG 特征的正规化。
5. 将检测窗口中所有 cell 的直方图连接起来，作为整个检测窗口的特征向量。

获得的特征向量可以使用 SVM 或其他机器学习算法进行分类。

一种实用的扩展是将所有均匀特征（如果一个局部二值特征至多只有 2 个 0-1 或 1-0 的变化，例如 00010000）分为一类。这样，可以将每个 cell 的特征向量的长度从 256 维减少到 59 维。

LBP 特征主要用于人脸识别与纹理分析。openALPR 的开发解释到，Haar 与 LBP 非常相似。区别在于 LBP 更快一些，特别是在一些没有浮点数处理器的嵌入式设备上。Haar 可能给出略微更好一些的结果，但是 Haar 的训练时间很慢。另外，LBP 具有在所有的东西上都能工作得很好的特性，不像一些其他检测器，只能作用在黑白车牌上。

2.4 Unconstrained Licence Plate and Text Localization and Recognition

该方法 [3] 在后来被称为 MSER (Maximally Stable Extremal Region) 方法。该方法被认为是计算机视觉中最有趣的点检测器之一。

MSER 是图片中的像素极值区域，即该区域的所有像素值均比他的外边界大 (MSER+)，或者该区域的所有像素值均比他的外边界小 (MSER-)。MSER 特征对光照变化具有不变性。

寻找 MSER 的线性时间算法如下：

Algorithm 5 CSER 检测算法

- 1: $T = 1, R^* = \emptyset, R = \emptyset$
- 2: **for all** 所有的像素 p 满足 $L(p) = T$ **do**
- 3: 添加像素: 如果 $\exists! r_i \in R, i = 1..n, p \in \partial r_i$ 那么 $r_i = r_i \cup p$ 。
- 4: 合并区域: 如果 $\exists r_i, r_j \in R, i, j = 1..n, i \neq j, p \in \partial r_i \wedge p \in \partial r_j$ 那么 $r_i = r_i \cup r_j \cup p \wedge R = R \setminus r_j$
- 5: 新区域: 如果 $\nexists r_i \in R, i, j = 1..n, p \in \partial r_i$ 那么 $r_{n+1} = p, R = R \cup r_{n+1}$
- 6: **end for**
- 7: 对于每一个新增或改变的区域 $r \in R$, 重新计算器特征。阳性分类区域 r_i 为 CSER

$$R^* = R^* \cup r_i$$

- 8: 如果 $T < T_{max}$, 那么 $T = T + 1$ 以及回到 2, 否则结束。
-

其中, I 是图像。而 R, R^* 分别是当前外部区域集合 (适当的阈值 T) 和 CSER(外部区域的子集)。

找到了图像中所有的 MSER 后, 这里以白底黑字的车牌为例, 介绍如何定位车牌, 其他类型的车牌二值化后可能需要反色来达到白底黑字的效果。



图 13: MSER 可以被用作视频序列车牌检测, MSER+ 可以找到车牌, 而 MSER-则可以分辨上面的字符。

可以看到, 车牌本身是一块 MSER+, 而他里面的字符是 MSER-。所以我们寻找的是一个较大的 MSER+, 包含一组较小的 MSER-。同时, 我们制定一系列规则, 来进一步筛选车牌:

1. MSER-大小相近
2. MSER-的中点几乎在一条线上 (水平方向的)
3. MSER+ 的高度与 MSER-高度的平均值相近
4. MSER+ 至少包含了 3 个 MSER-

这样筛选出来的 MSER+ 就是车牌区域, 而 MSER-区域可以作为车牌字符分割的结果。所以 MSER 方法是非常高效的。

2.5 自然环境下的车牌定位与字符分割方法的研究

这篇论文 [11] 的第三章使用了粗定位与精确定位两个阶段, 组合了多种方法, 实现了车牌定位。通过车牌粗定位, 车牌候选区域将从图像内众多的区域中保存并突现出来; 通过车牌精确定位, 车牌在图

像中的位置将得到更加准确的定位，而且粗定位后残留下来的伪车牌区域也将被剔除。

车牌定位算法的整体思路简述如下：

1. 利用区域生长算法求得二值图像中所有的连通区域，并利用高度阈值进行筛选，删除掉过高和过矮的干扰区域。




图 14: 高度筛选后的二值图像

2. 对图中所有高度适合的连通区域进行水平聚类，剔除横纵比、面积、梯度密度超出阈值范围的聚类区域，这样保留下来的每个聚类区域就作为一个车牌候选区域，粗定位阶段处理完毕。判定两区域水平相关（可以聚为一个类）的准则关系如下：

$$\begin{cases} |Y_{Mid}^i - Y_{Mid}^j| \leq \Delta y \\ X_{Min}^j - X_{Max}^i \leq \Delta X \\ |H_j - H_i| = \Delta xy \end{cases}$$

水平聚类算法如下：

输入：高度适合的连通区域数组 a_1, a_2, \dots, a_m

输出：若干个连通域水平聚类

算法：

- (a) 读入二值梯度图像中所有高度适合的连通区域，将它们按照区域左边缘水平坐标从小到大的顺序排列得到 b_1, b_2, \dots, b_m 。
- (b) 从 $i = 1$ 开始，按顺序取得一个连通区域 b_i 。
- (c) 若该区域 b_i 已经标记左或右邻近区域的标号，则 $i + 1$ ，转回 (b)。
- (d) 将该区域 b_i 作为一个水平区域聚类的头区域，初始化此聚类区域的属性集合即 b_i 的属性集合，开始下边的计算。
- (e) 在 b_i 的右侧找寻第一个满足水平相关准则的相关右邻接区域 b_j 。
- (f) 若找到 b_j ，则标记好 b_i 和 b_j 邻接关系，合并两区域 $b_i = b_i \cup b_j$ ，重新计算 b_i 的属性集合，转回 5。若找不到 b_j ，则 $i + 1$ ，转回 (b)，开始遍历下一个水平区域聚类。

设该区域聚类 i 的各属性为：外接矩形 $Rect^i$ ，高度 H^i ，宽度 W^i ，梯度密度 ρ_{Grad}^i ，则具体筛选规则描述如下：

Del i Subject to

$$\{\frac{H^i}{W^i}\} \cup \{(W^i \times H^i) \notin \Omega^S\} \cup \{\rho_{Grad}^i < \Delta\rho_{Grad}\} \cup \{(Rect^i/2) \subseteq Rect^j\}$$

这里选择的是较为宽松的阈值范围，为了不把真的车牌误删。而选入的非车牌区域可以在精确定位时被舍弃。

3. 车牌区域精确定位。

对每个车牌候选区域，

- (a) 利用其梯度形态特征分割得到车牌精确的上下边界：引起车牌上下边界不确定的主要因素是出租车下边的小车牌。对该候选区域进行水平梯度化、二值化、平滑去噪以及形态学膨胀之后得到 b) 图像。对该二值图像进行逐行水平扫描，找到引起宽度跳变的行数值，也就找到了大小车牌的交接点。具体实现时，可以从下向上扫描，当首次找到当前行的 2/3 还大于前一扫描行的时候，停止扫描认定其即为交接点，删掉此行下面的所有区域。



- (b) 对剩下部分彩色子图像进行 HSV 色彩变换我国车牌包含了四种不同的配色方案，分别为蓝底白字 (以下简称为蓝牌)、黄底黑字 (黄牌)、白底黑字 (白牌) 和黑底白字 (黑牌)。作者通过查阅文献，得到这些颜色的 HSV 分量的分布范围：

表 3-1 HSV 三分量范围 (—表示该值不予考虑)

Table 3-1 HSV distributing scope (—express taking no account of the value)

	蓝色	黄色	白色	黑色
<i>H</i>	[180 ~ 250]	[25 ~ 60]	—	—
<i>S</i>	[0.2 ~ 1]	[0.2 ~ 1]	[0 ~ 0.1]	—
<i>V</i>	[60 ~ 255]	[60 ~ 255]	[200 ~ 255]	[0 ~ 90]

在寻找车牌左右边界时，我们以候选区域的高度作为标度创建平移窗口。设候选区域高度为 H ，宽度为 W ，确定左右边界过程如下：

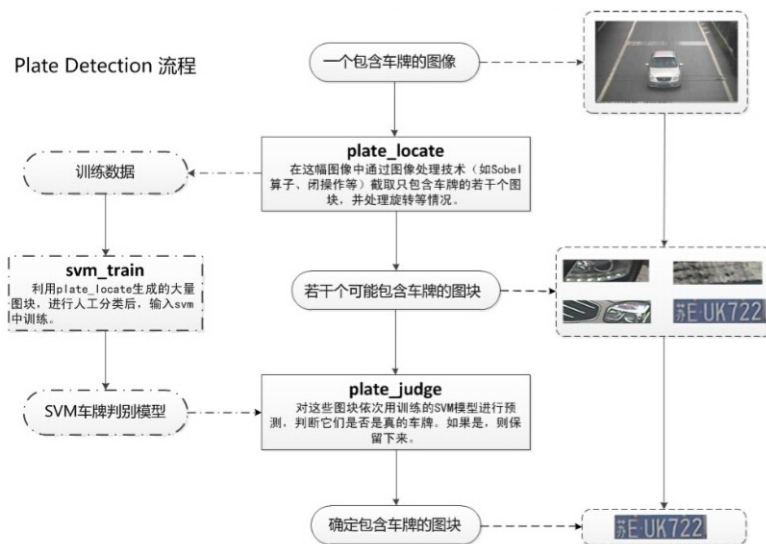
- i. 当 $W \leq H \times 6$ 时，不用再确定车牌的左右边界，原候选区域即车牌的精确定位位置，只须以整个候选区域作为窗口判断出车牌的种类即可；
- ii. 当 $W > H \times 6$ 时，按照宽度为 $H \times 6$ ，高度为 H 的窗口水平移动扫描候选区域，通过窗口平移找到每种配色方案概率值最大的窗口位置，比较这几种车牌配色的概率极值，最终取概率极值最大配色作为车牌种类，而该极值配色对应的窗口区域即为车牌的精确定位位置。
- iii. 并且设定一个最小配色概率阈值，若当前极值配色概率值小于最小配色概率阈值，则认为该区域没有车牌，该区域为伪车牌。

实验表明，该车牌检测和定位方法具有很好的实时性，且定位准确率高，为后面的车牌字符分割打下了良好的基础。不足之处在于在定位阶段过后留下了一些伪车牌区域没有被剔除。

2.6 开源系统 EasyPR 中用到的形态学方法与颜色定位法。

2.6.1 使用 Sobel 寻找垂直边缘


Plate Detection 的总流程如下：




PlateLocate 就是比较关键的车牌定位，流程如下：

1. 高斯模糊，去除干扰噪声，为边缘检测算法做准备。
高斯模糊中的半径也会给结果带来明显的变化。有的图片，高斯模糊半径过高或过低，车牌都无法定位。因此，高斯模糊的半径既不宜过高，也不能过低。作者对于近千张图片经过测试后得出的综合定位率最高的值为 5。
2. 灰度化（OpenCV Sobel 运算只能作用在灰度图像上）
3. 进行 Sobel 运算，得到一阶水平方向导数。用于垂直边缘检测。由于车子前端干扰性的水平边缘较多，这里只对水平方向求导，得到垂直边缘。
4. 二值化
5. 闭操作，目的是将车牌字符区域连接成一个连通域，以便取轮廓。闭操作就是对图像先膨胀，再腐蚀，闭操作的结果一般是可以将许多靠近的图块相连成为一个无突起的连通域。

其中，作者推荐矩形模板的宽度大于等于 17，高度一般为 3。因为中国车牌有一个特点，就是表示城市的字母与右边相邻的字符距离远大于其他相邻字符之间的距离。如果宽度设置不够大，左边的字符与右边的字符会断开：



宽度过大也是不好的，因为它会导致闭操作连接不该连接的部分，例如下图的情况。



下图是合适宽度下的结果：



6. 求轮廓（OpenCV 函数 `findContours`）。将连通域的外围勾画出来，以便形成外接矩形（Rotate-

dRect)。

7. 筛选。对轮廓求最小外接矩形，然后验证，不满足条件的淘汰。尺寸判断：中国车牌的一般大小是 $440mm \times 140mm$ ，面积为 440×140 ，宽高比为 3.14。使用如下方法判断矩形是否是车牌：


- (a) 设立一个偏差率 error，根据这个偏差率计算最大和最小的宽高比 rmax、rmin。判断矩形的 r 是否满足在 rmax、rmin 之间。
- (b) 设定一个面积最大值 max 与面积最小值 min。判断矩形的面积 area 是否在 max 与 min 之间。

以上两个条件必须同时满足，任何一个不满足都代表这不是车牌。

尺寸筛选后的结果：



8. 角度判断与旋转。把倾斜角度大于阈值 (如正负 30 度) 的矩形舍弃。余下的矩形进行微小的旋转，使其水平。最后得到了如下三个矩形：



9. 统一尺寸。作者使用了 136×36 。

整个过程流程图表示如下：

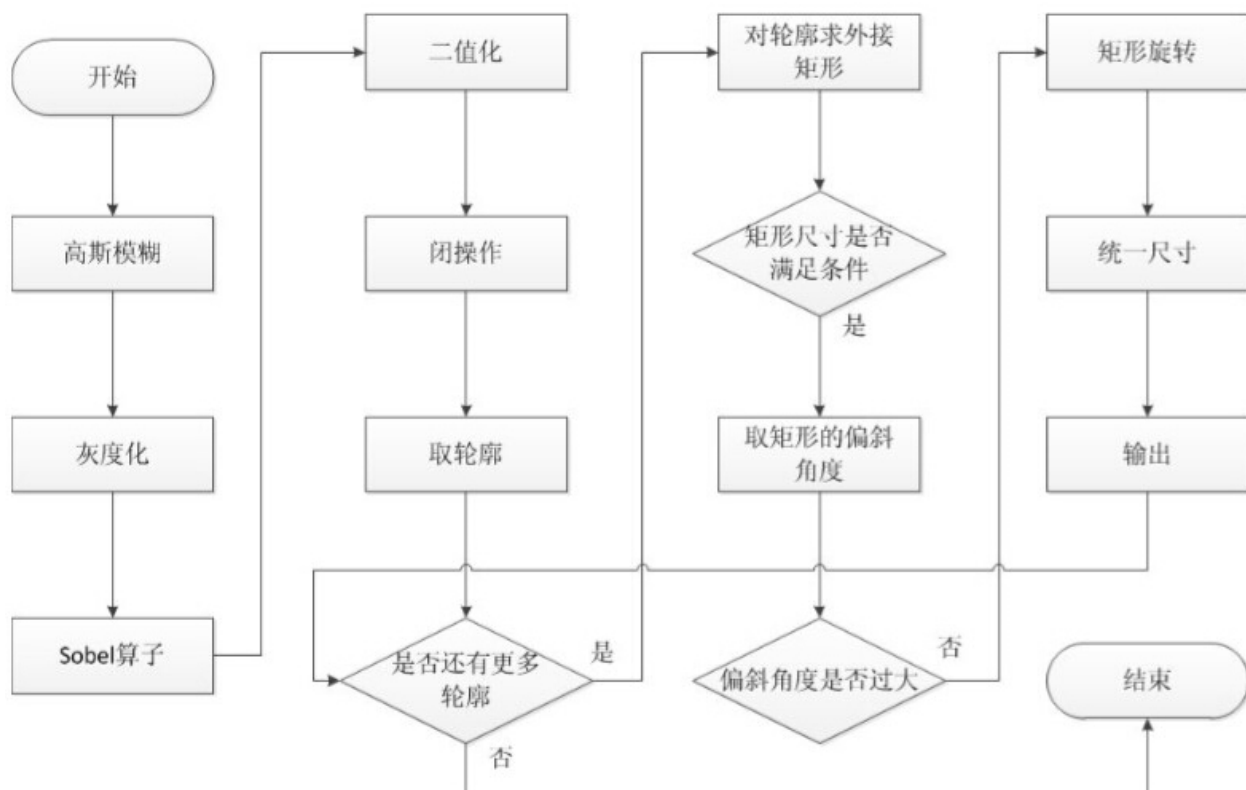


图 15: plateLocate 流程图

2.6.2 颜色定位与偏斜扭正

2.6.1 节介绍的 Sobel 法最大的问题在于面对垂直边缘交错的情况下，无法准确定位车牌：



如果将颜色定位与 Sobel 定位加以结合的话，可以使车牌的定位准确率从 75% 上升到 94%。这里选择使用 HSV 模型，对于颜色判断比较直观，例如蓝色的判断：



颜色定位的完整过程如下：

1. 将图像的颜色空间从 RGB 转为 HSV，由于光照的影响，对于图像使用直方图均衡进行预处理；
2. 依次遍历图像的所有像素，当 H 值落在 200-280（蓝色），且 S 值与 V 值也落在 0.35-1.0 之间，标记为白色像素，否则为黑色像素，这样，这里的蓝色区域就全部变成了白色像素，其余像素全为黑色。相当于使用了蓝色模板，筛选出了蓝色区域。

一幅图像需要进行一次蓝色模板的匹配，还要进行一次黄色模板的匹配，以此确保蓝色和黄色的车牌都被定位出来。

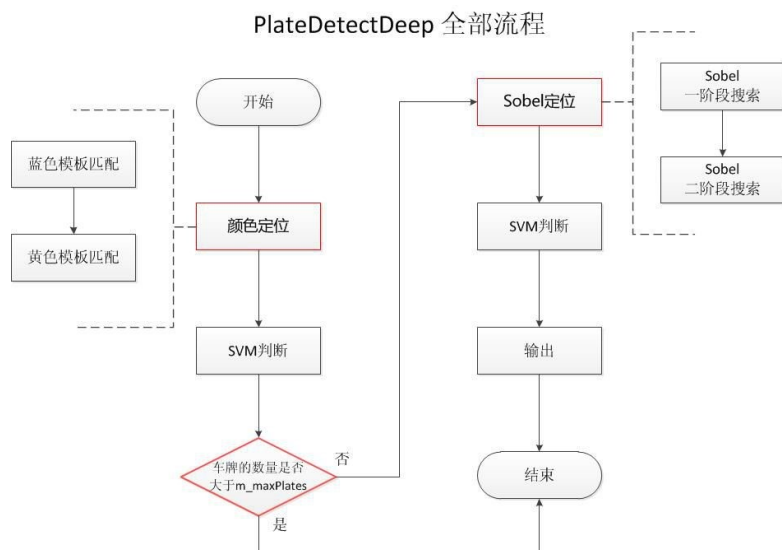
3. 对仅有白黑两个颜色的二值图参照原先车牌定位中的方法，使用闭操作，取轮廓等方法将车牌的外接矩形截取出来做进一步的处理。

但是颜色定位不是万能的，面对光线不足、或者蓝色车身时，颜色定位很糟糕。这时可以再结合 2.6.1 节的 Sobel 方法。

2.6.3 EasyPR 现阶段的车牌定位方式

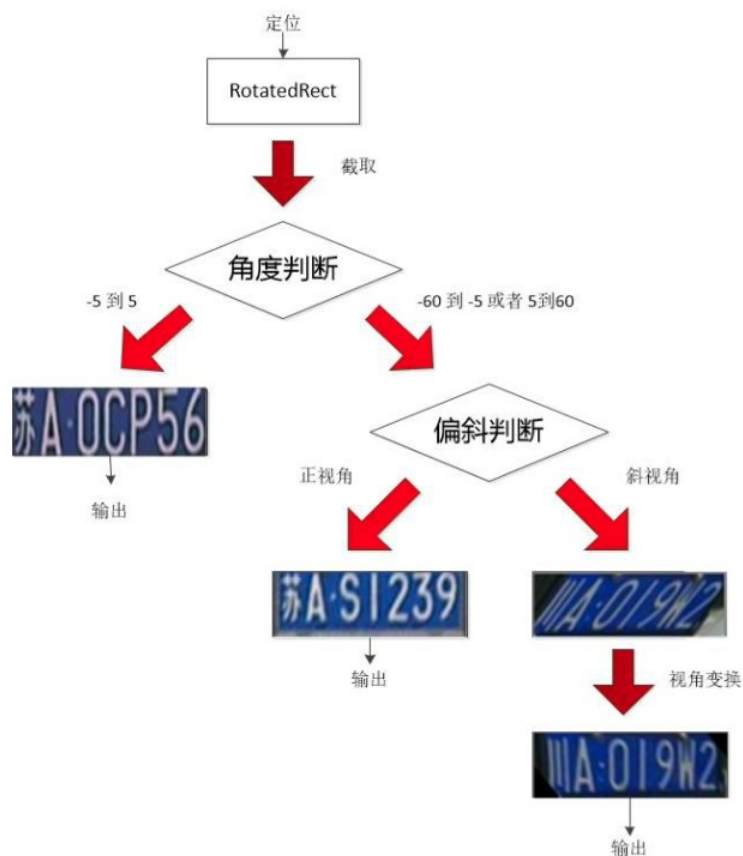
目前的新版本使用了颜色定位与 Sobel 定位结合的方式。首先进行颜色定位，然后根据条件使用 Sobel 进行再次定位，增加整个系统的适应能力。

为了加强鲁棒性，Sobel 定位法可以用两阶段的查找。也就是在已经被 Sobel 定位的图块中，再进行一次 Sobel 定位。这样可以增加准确率，但会降低速度。一个折衷的方案是让用户决定一个参数 `m_maxPlates` 的值，这个值决定了你在一幅图里最多定位多少车牌。系统首先用颜色定位出候选车牌，然后通过 SVM 模型来判断是否是车牌，最后统计数量。如果这个数量大于你设定的参数，则认为车牌已经定位足够了，不需要后一步处理，也就不会进行两阶段的 Sobel 查找。相反，如果这个数量不足，则继续进行 Sobel 定位。



2.6.4 偏斜扭转

由于现实场景中拍摄到的车牌可能是倾斜的，也有可能是在斜视角下拍摄的，所以在这里需要调整，以便后面的字符分割与识别。整体流程如下图：



1. ROI (region of interest) 的截取。

使用 RotatedRect 的 boundingRect() 方法。返回一个 RotatedRect 的最小外接矩形，传递给 Mat(Rect...) 方法就可以截取出原图的 ROI 图块，获得对应的 ROI 图像 (clone or copyTo)。

2. 扩大化旋转。

在获得 RotatedRect 时，我们就已经知道了车牌的倾斜角度，所以若角度较小，则直接输出，否则，需要作旋转操作。

为了防止旋转后车牌区域的一部分被截断：



需要首先新建一个尺寸为原始图像 1.5 倍的新图像，接着把原始图像映射到新图像上，于是我们得到了一个显示区域（视框）扩大化后的原始图像。显示区域扩大以后，那些在原图像中没有值的像素被置了一个初值。

接着调用 warpAffine 函数，使用新图像的大小作为目标图像的大小。warpAffine 函数会将新图像旋转，并用目标图像尺寸的视框去显示它。于是我们得到了一个所有感兴趣区域都被完整显示的旋转后图像。

这样，我们再使用 getRectSubPix() 函数就可以获得想要的车牌区域了：



3. 偏斜判断。

为了判断二值化图像中白色的部分是平行四边形。一种简单的做法就是从图像中选择一些特定的行。计算在这个行中，第一个全为 0 的串的长度。从几何意义上来看，这就是平行四边形斜边上某个点距离外接矩形的长度。


假设我们选择的这些行位于二值化图像高度的 $\frac{1}{4}, \frac{2}{4}, \frac{3}{4}$ 处的话，如果白色图形是矩形的话，这些串的大小应该是相等或者相差很小的，相反如果是平行四边形的话，那么这些串的大小应该不等，并

且呈现一个递增或递减的关系。通过这种不同，我们就可以判断车牌区域里的图形究竟是矩形还是平行四边形。

偏斜判断的另一个重要作用就是，计算平行四边形倾斜的斜率，这个斜率值用来在下面的仿射变换中发挥作用。我们使用一个简单的公式去计算这个斜率，利用上面判断过程中使用的串大小，假设二值化图像高度的 $\frac{1}{4}, \frac{2}{4}, \frac{3}{4}$ 处对应的串的大小分别为 len1, len2, len3, 车牌区域的高度为 Height。一个计算斜率 slope 的计算公式就是：

$$(len3 - len1) / Height * 2$$

Slope 的直观含义见下图：



需要说明的，这个计算结果在平行四边形是右斜时是负值，而在左斜时则是正值。于是可以根据 slope 的正负判断平行四边形是右斜或者左斜。


在实践中，会发生一些公式不能应对的情况，例如像下图这种情况，斜边的部分区域发生了内凹或者外凸现象。这种现象会导致 len1, len2 或者 len3 的计算有误，因此 slope 计算也会不准。



为了实现一个鲁棒性更好的计算方法，可以用 $(len2 - len1) / Height \times 4$ 与 $(len3 - len1) / Height \times 2$ 两者之间更靠近 $\tan(\text{angle})$ 的值作为 solpe 的值（在这里，angle 代表的是原来 RotataedRect 的角度）。多采取了一个 slope 备选的好处是可以避免单点的内凹或者外凸。

4. 仿射变化。

使用 opencv 的 warpAffine 函数，为保证新的视框中心能够正好与车牌的中心重合，我们可以选择偏移 $xidff/2$ 长度。正如下图所示显示的一样。



视框往右偏移的含义就是目标图像 Mat 的原点往右偏移。如果原点偏移的话，那么仿射后图像的三个关键点的坐标要重新计算，都需要减去 $xidff/2$ 大小。

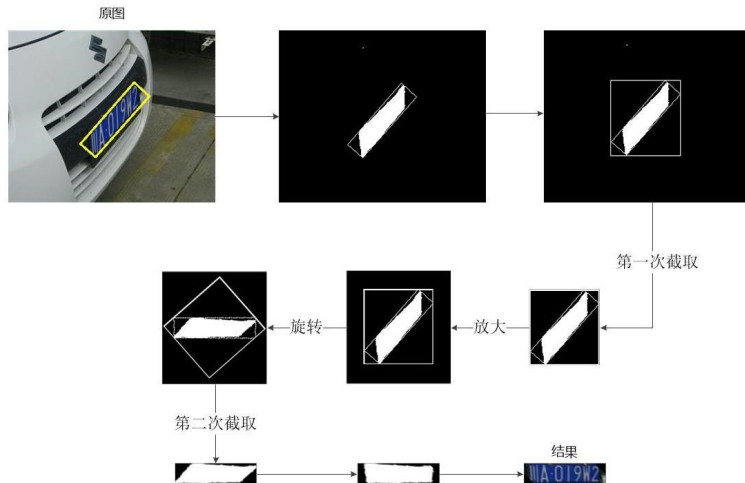
重新计算的映射点坐标为下：

```
plTri[0] = Point2f(0 + xiff, 0);  
plTri[1] = Point2f(width - 1, 0);  
plTri[2] = Point2f(0, height - 1);  
dstTri[0] = Point2f(xiff/2, 0);  
dstTri[1] = Point2f(width - 1 - xiff + xiff/2, 0);  
dstTri[2] = Point2f(xiff/2, height - 1);
```

效果图：

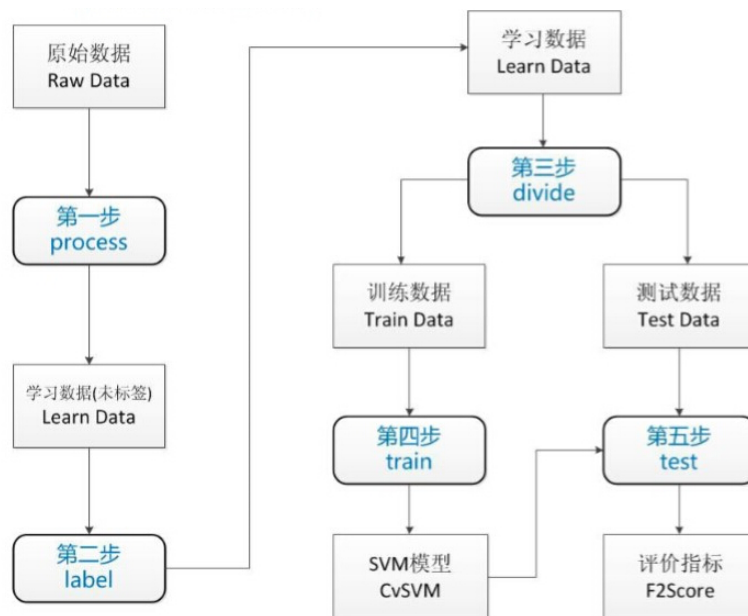


偏斜扭正全过程：



2.6.5 SVM 训练

流程如下图：



作者使用了 opencv 相关函数，在这里不赘述了。值得一提的是，人工对数据进行标签是一件非常耗时的事情，于是作者提出了“逐次迭代自动标签法”：

方法核心很简单。就是假设你有 3000 张未分类的图片。你从中选出 1%，也就是 30 张出来，手工给它们每个图片进行分类工作。如今你有了 30 张贴好标签的数据了，下一步你把它直接输入到 SVM 模型中训练，获得了一个简单粗旷的模型。之后，你从图片集中再取出 3% 的图片，也就是 90 张，然后用刚训练好的模型对这些图片进行预测，根据预测结果将它们自动分到 hasplate 和 noplate 文件夹下面。分完以后，你到这两个文件夹下面，看看哪些是预测错的，把 hasplate 里预测错的移动到 noplate 里，反之，把 noplate 里预测错的移动到 hasplate 里。

接着，你把一开始手工分类好的那 30 张图片，结合调整分类的 90 张图片，总共 120 张图片再输

入 svm 模型中进行训练。于是你获得一个比最开始粗旷模型更精准点的模型。然后, 你从 3000 张图片中再取出 6% 的图片来。用这个模型再对它们进行预测, 分类....

以上反复。你每训练出一个新模型, 用它来预测后面更多的数据, 然后自动分类。这样做最大的好处就是你只需要移动那些被分类错误的图片。其他的图片已经被正确的归类了。注意, 在整个过程中, 你每次只需要对新拿出的数据进行人工确认, 因为前面的数据已经分好类了。因此, 你最好使用两个文件夹, 一个是已经分好类的数据, 另一个是自动分类数据, 需要手工确认的。这样两者不容易乱。

每次从未标签的原始数据库中取出的数据不要多, 最好不要超过上次数据的两倍。这样可以保证你的模型的准确率稳步上升。如果想一口吃个大胖子, 例如用 30 张图片训练出的模型, 去预测 1000 张数据, 那最后结果跟你手工分类没有任何区别了。

3 字符分割

字符分割

4 字符识别

字符识别

5 总结

一个完整的车牌字符检测系统主要由上文中论述的车牌定位、字符分割与字符识别三大部分组成。其中, 用于车牌定位的方法主要分为两大类, 机器学习中的 Adaboost 方法结合 Haar 等特征, 或者是传统的视觉方法。字符分割任务中, 目前普遍采用的是传统方法, 笔者曾经尝试过自己实现一个字符分割器, 发现特定的方法对于输入图片的要求比较高, 对于一些畸形的情况, 分割情况很糟糕。字符识别方法也主要分为两大类, 一大类机器学习中的各种统计、混合分类器与神经网络分类器方法, 另一大类是模式、模板匹配方法, 但模式、模板匹配方法提出时间较早, 较为不灵活。

另一方面, 笔者考察了两个目前较大的开源车牌检测系统, EasyPR 与 openALPR, 这些可以投入使用的系统还是偏向于传统方法, 只在字符识别中, 采用了目前已经相当成熟的 SVM 分类器。开发者在回答使用者提出的 Issue 时, 也提到了学术界提出的很多方法, 在实际测试中并不能取得很好的结果, 原因可能在于实际中输入的图片各种各样, 光线、偏斜、扭曲、清晰度等等方面的因素都会影响检测的准确率。

虽然开源项目偏向于传统方法, 笔者认为, 在未来, 随着数据集的增大, 机器学习方法将在车牌检测系统中获得更大的应用, 这些自适应的方法应对各国各地区格式不一的车牌、应对实际拍摄中的偏差应该更为有优势。事实上, 车牌检测是一个古老的任务, 但是直到今天, 其准确率还是不能令人满意的, 说明传统方法难以越过某个准确度上界, 而还在发展中的机器学习方法应用于实际问题时还需要更多方面的考量。笔者认为, 随着机器学习与计算机视觉的发展, 这个问题应该可以找到更好的解决方案。

参考文献

- [1] *Inter-stage feature propagation in cascade building with AdaBoost*. IEEE, Aug. 2004.

- [2] *Learning object detection from a small number of examples: the importance of good features*. IEEE, June 2004.
- [3] *Unconstrained licence plate and text localization and recognition*. IEEE Intelligent Transportation Systems, Sept. 2005.
- [4] Horst Bischof Clemens Arth, Florian Limberger. Real-time license plate recognition on an embedded dsp-platform. In *Conference on Computer Vision and Pattern Recognition*, pages 1–8, Minneapolis, MN, June 2007. IEEE.
- [5] Louka Dlagnekov. *License Plate Detection Using AdaBoost*. PhD thesis, UC San Diego, 2004.
- [6] Horst Bischof Michael Donoser, Clemens Arth. Detecting, tracking and recognizing license plates. In *Asian Conference on Computer Vision*. AFCV, 2007.
- [7] Michael J. Jones Paul Viola. Robust real-time face detection. *International Journal of Computer Vision*, 57:137–154, 2004.
- [8] William R. Schwartz D. Menotti R. F. Prates, G. Cámara-Chávez. Brazilian license plate detection using histogram of oriented gradients and sliding windows. *International Journal of Computer Science and Information Technology*, 5:39–52, 2013.
- [9] A. L. Yuille Xiangrong Chen. Detecting and reading text in natural scenes. In *Computer Vision and Pattern Recognition*. IEEE, June 2004.
- [10] Rob Schapire Yoav Freund. A tutorial on boosting. <http://www.research.att.com/~yoav>, <http://www.research.att.com/~schapire>.
- [11] 于深洋. 自然环境下的车牌定位与字符分割方法的研究. Master’s thesis, 哈尔滨工业大学, 2006.